

Ý tưởng #1: Hệ thống Phân cụm động và Dự đoán Giá trị Vòng đời Khách hàng (Customer Lifetime Value - CLV).

TỔNG QUAN

Project này không chỉ chạy một thuật toán, mà là một chuỗi (pipeline) dùng nhiều góc khác nhau của cái map scikit-learn kia.

- **Phần tiền xử lý data (Chỗ ăn điểm cốt lõi):** Dữ liệu giao dịch bán hàng thực tế lúc nào cũng "nát". Bạn sẽ phải làm sạch các giao dịch rác/hoàn trả, xử lý missing value, và quan trọng nhất là Feature Engineering. Bạn sẽ phải tự code để tính ra các chỉ số RFM (Recency - dạo này có mua không, Frequency - mua tần suất ra sao, Monetary - tiêu tổng bao nhiêu tiền) cho từng khách hàng, sau đó chuẩn hóa (Scaling) đồng data đó.
- **Áp dụng scikit-learn map:**
 - **Phase 1 - Clustering (Nhìn góc dưới bên trái map):** Đang không có nhãn (unlabeled data) đúng không? Nhìn theo mũi tên, bạn quát **KMeans** hoặc **MiniBatchKMeans** để tự động gom nhóm khách hàng (ví dụ: nhóm VIP, nhóm hay săn sale, nhóm "ngủ đông").
 - **Phase 2 - Regression (Nhìn góc trên bên phải map):** Giờ bạn muốn dự đoán ra một con số (Predicting a quantity). Bạn kết hợp dữ liệu gốc và cái nhãn cụm vừa tạo ở Phase 1 làm đầu vào. Chạy theo mũi tên, bạn thử **SVR** hoặc đập luôn **Ensemble Regressors** (như Random Forest) để dự đoán xem trong 6 tháng tới, khách hàng này sẽ đem lại doanh thu cụ thể là bao nhiêu tiền.
 - **Phase 3 - Classification (Góc trên bên trái - Mở rộng thêm):** Chuyển sang dự đoán danh mục (Predicting a category). Dùng **Ensemble Classifiers** để phân loại xem một khách hàng có nguy cơ "Churn" (rời bỏ nền tảng, không mua nữa) hay không (Yes/No).

GIẢI THÍCH

Bạn đang xây một hệ thống trả lời 3 câu hỏi:

1. **Khách hàng của mình thuộc loại nào?** (VIP, mua ít, ngủ đông,...)
2. **Trong tương lai họ sẽ mang lại bao nhiêu tiền?**

3. Họ có sắp bỏ mình không? (churn)

👉 Tức là 1 project nhưng gồm **3 bài toán ML** khác nhau nối thành **pipeline**.

💡 Phase 0: Tiền xử lý (Quan trọng nhất)

Đây là chỗ ăn điểm nhiều nhất, không phải model đâu.

Bạn có data kiểu này:

- customer_id
- invoice_date
- amount
- product
- ...

Bạn phải biến nó thành dạng "mỗi khách hàng = 1 dòng"

👉 Tự tính ra **RFM**:

- **Recency (R)**: lần mua gần nhất cách hiện tại bao lâu
- **Frequency (F)**: mua bao nhiêu lần
- **Monetary (M)**: tổng tiền đã tiêu

Ví dụ:

custor	R	F	M
A	2 ngày	10 lần	5 triệu
B	100 ngày	1 lần	200k

👉 Sau đó:

- scale lại (StandardScaler)
 - xử lý missing
 - bỏ data rác (refund, âm tiền,...)
-

● Phase 1: Clustering (Không có nhãn)

👉 Câu hỏi: “*Khách hàng tự nhiên chia thành mấy nhóm?*”

Bạn dùng:

- KMeans / MiniBatchKMeans

👉 Model sẽ tự chia, ví dụ:

- Cluster 0: VIP (F cao, M cao)
- Cluster 1: ngủ đông (R lớn)
- Cluster 2: sẵn sale (F cao, M thấp)

👉 Output: mỗi khách hàng có thêm 1 cột:

cluster = 0 / 1 / 2 / ...

● Phase 2: Regression (Dự đoán tiền)

👉 Câu hỏi: “*6 tháng tới khách này mang lại bao nhiêu tiền?*”

Bạn dùng:

- Random Forest Regressor (dễ ăn điểm)
- hoặc SVR

Input:

- R, F, M
- cluster (từ Phase 1)

Output:

- số tiền (VD: 3 triệu)

👉 Đây gọi là **Customer Lifetime Value (CLV)**

● Phase 3: Classification (Churn)

👉 Câu hỏi: “*Khách này có sắp bỏ không?*”

Bạn định nghĩa churn:

- Ví dụ: 90 ngày không mua → churn

Model:

- Random Forest Classifier
- Logistic Regression

Output:

- Yes / No
-

💡 Hiểu đơn giản bằng 1 flow:

Raw data



Tính RFM



Clustering → biết loại khách



Regression → dự đoán tiền



Classification → dự đoán bỏ đi

🎯 Vì sao project này “xịn”?

Vì bạn dùng đủ combo:

- Unsupervised Learning (Clustering)
- Supervised Learning (Regression + Classification)
- Feature Engineering (RFM)

👉 Đây đúng kiểu project “full pipeline” → CV rất mạnh.

 Nói thật với bạn

Ý tưởng này **không khó về thuật toán**, nhưng:

- Khó ở **xử lý data + logic business**
 - Và **giải thích kết quả cho dễ hiểu**
-

Ý tưởng triển khai

Nếu trong buổi bảo vệ hoặc phỏng vấn, bạn show được những thứ này, họ sẽ thấy bạn không hề "non":

- **Logic Business (RFM)**: Bạn không chỉ biết code, bạn còn biết dùng toán để định nghĩa khách hàng (Recency, Frequency, Monetary). Điều này chứng tỏ bạn có **Domain Knowledge** (kiến thức ngành).
- **Xử lý Data "Nát"**: Việc bạn biết xử lý những đơn hàng bị hoàn trả (negative amount), khách hàng ảo, hay chuẩn hóa dữ liệu (Scaling) bằng **StandardScaler** chứng tỏ bạn đã "va chạm" thực tế.
- **Sự kết hợp Unsupervised + Supervised**: Rất ít sinh viên dám kết hợp K-Means với Random Forest trong cùng một project. Việc này cho thấy bạn hiểu sâu cái "Map" của Scikit-learn.

Để đạt mức "Junior cứng", Linh cần chú ý:

Để project này không bị đánh giá là "làm cho vui", bạn hãy chuẩn bị kỹ 3 câu hỏi này:

1. **Tại sao chọn K=3 hay K=5 trong Clustering?** (Hãy tìm hiểu về *Elbow Method*).
2. **Làm sao biết Model dự đoán tiền (Regression) là đúng?** (Dùng *MAE* hay *RMSE* như mình nói lúc nãy).
3. **Tại sao dùng Random Forest mà không dùng Linear Regression?** (Vì dữ liệu khách hàng thường không tuyến tính).

Lời khuyên "thực chiến" cho Linh:

Dự án này rất mạnh về mặt **Visualization** (Hình ảnh hóa).

- Hãy vẽ cái biểu đồ 3D cho RFM trước và sau khi phân cụm (Clustering).
- Hãy vẽ biểu đồ tròn (Pie chart) xem nhóm VIP chiếm bao nhiêu %.

Chốt lại: Nếu làm xong và chạy mượt, bạn hoàn toàn có thể tự tin ghi vào CV để apply thực tập (Intern) hoặc vị trí Junior Data/AI ở các công ty lớn. Đây là một project "có thịt có xương", không phải mấy bài toán phân loại hoa hay chữ số viết tay cơ bản đâu!